

Анализ расхождений оригинальных либретто мюзиклов и их адаптаций на русском языке

Выполнила:

Анастасия Бутакова

Идея проекта

При переводе текстов с одного языка на другой неизбежно появляются различия — от небольших деталей до ощутимого сдвига смыслов.

Насколько сильные изменения претерпевают стихотворные тексты, а точнее — песенные? У них дополнительные сложности:

- специфическая структура — куплеты и припевы, которые повторяются
- перевод должен укладываться в ритм музыкального материала
- возможные изменения текстов за счет адаптации сюжетных элементов, хореографии, логики постановки для страны, которая ставит иностранный спектакль

Сравним оригинальные либретто мюзиклов на английском языке и их переводы на русский, в которых их ставили по лицензии.

Реализация

Цель проекта:

Проанализировать, насколько семантически близки оригинальные тексты мюзиклов и их официальные русскоязычные – в общем виде и на практике.

Задачи:

- Рассчитать косинусную близость оригиналов и переводов
- Попытаться выявить содержательные расхождения при их наличии
- Прояснить технические моменты работы с песенными текстами

Данные

Тексты либретто мюзиклов – оригинал на английском языке и перевод на русский, использованный в официальных постановках в России:

- Mamma Mia! / Мамма мия
- Cats / Кошки
- Chess / Шахматы
- Hair / Волосы
- Jekyll & Hyde / Джекилл и Хайд
- Jesus Christ Superstar / Иисус Христос – Суперзвезда
- Sound of Music / Звуки музыки

→ 157 пар текстов песен (англ-рус) для анализа, всего 314 отдельных текстов

Инструменты и библиотеки

- requests, BeautifulSoup – парсинг данных
- регулярные выражения, nltk, spacy, rymorphu3 – предобработка текстов
- визуализация результатов: matplotlib
- LaBSE (Language-Agnostic BERT Sentence Embedding) – для сравнения текстов на разных языках в рамках одного векторного пространства
- WordCloud, Counter – ключевые слова

Реализация проекта

- LaBSE
- WordCloud + частотность

Подготовка текстов

Предварительный этап:

- сопоставление выгруженных текстов на английском и переводов на русский
- удаление обозначений говорящих/поющих из текстов (Anatoly&Florence, СТАРИК ДЬЮТЕРОНОМИ:, Maria (spoken), 1st newsboy:, хор, ВСЕ ВМЕСТЕ:)

Легкая предобработка – для LaBSE:

- удаление лишних переносов строк и пробелов
- очистка от нерелевантных фрагментов текста (добавочная информация в скобках, количество повторов строки, пометки о сценографии и т.д.)
- замена Ё на Е в целях единообразия (часть текстов с ё, часть без)


Глубокая предобработка – для облака слов и выделения ключевых слов с Counter:

- перевод в нижний регистр
- замена всех пробельных символов на пробелы, удаление пунктуации
- токенизация, лемматизация (разные способы для английского и русского)
- удаление стоп-слов из дополненных списков
- перевод данных в формат, где 1 наблюдение = 1 песня (мюзикл – название песни – текст песни – язык), а не пара оригинал-перевод

Корректировка корпуса

- Удаление песен со слишком маленьким количеством строк. Проверка и ручная правка слишком длинных текстов, особенно если перевод и оригинал заметно различаются по количеству строк.

Распределение текстов песен в мюзиклах по длине



Построение мультязычной модели эмбеддингов

LaBSE – трансформер на базе BERT, предназначенный для работы с текстами на разных языках и создания универсальных эмбеддингов


- векторные представления оригиналов и переводов в одном пространстве
- анализ схожести без оглядки на язык текста через косинусную близость

Опробованы две модели:

- обычная LaBSE «из коробки»
 - LaBSE с явным добавлением пулинга
- Пулинг лучше показывает сходство текстов по смыслу, т.к. документы не проходят через несколько дроблений и усреднений
- результат надежнее, выше и с меньшим разбросом значений

Далее опираемся модель с ним.


Распределение значений косинусной близости:
оригинальный текст песни vs. официальная адаптация на русский



Результаты

Косинусная близость оригиналов и переводов

Тексты в целом имеют **достаточно высокую** косинусную близость, что говорит об отсутствии радикальных различий в содержании, появившихся при адаптации. **Самая идентичная** пара оригинал-перевод – «Кошки».



Наиболее сильный размах значений – спектакли на спорные темы + обычно чаще сюжетно и концептуально изменяются постановщиками:

1. «Шахматы» – политика, Холодная война + изменение акцентов в зависимости от страны постановки
2. «Иисус Христос Суперзвезда» - религия + традиционно много экспериментов в адаптациях

Ключевые слова оригиналов и переводов в разных вариантах текстов (I)

Без повторяющихся строк

Cats

eng: cat, like, eye, find, time, day, life, old, tell, bright, sit, night

rus: кот, имя, сидеть, новый, свет, дом, кошка, лишь, луна, играть, ночь, идти

3 совпадения (+ 1 вероятное) == 3 совпадения (+ 1 вероятное) // различаются: 1

Chess

eng: want, game, good, like, chess, time, love, leave, win, life, play, feel

rus: лишь, игра, ждать, понять, мир, должный, хотеть, друг, верить, время, жизнь, игрок

4 (+ 1) → 5 (+ 1) // различаются: нет + 1 новое (появилось в рус. → пара)

Hair

eng: love, boy, black, white, song, believe, air, hair, tell, life, god, like

rus: мир, любовь, бег, чёрный, простить, песня, свет, дым, белый, волос, бог, господа

6 == 6 // различаются: 1

Jekyll & Hyde

eng: way, find, life, time, day, like, dream, eye, new, look, love, evil

rus: ужас, лишь, жизнь, дать, ждать, путь, новый, свет, хотеть, глаз, искать, фасад

5 (+ 1) → 4 (+ 2) // различаются: 1 + 1

одинаковый цвет выделения – совпадающие ключевые слова
одинаковый цвет букв без выделения – могут быть аналогичны друг другу в данном случае

В изначальном виде

Cats

eng: cat, like, eye, old, sit, find, time, bright, day, life, tell, moon

rus: кот, сидеть, имя, новый, ночь, свет, дом, играть, кошка, идти, луна, лишь

Chess

eng: want, good, like, time, game, chess, win, love, leave, life, feel, play

rus: игра, ждать, лишь, понять, мир, должный, жизнь, время, хотеть, верить, друг, хороший

Hair

eng: love, boy, white, hare, believe, hair, black, song, long, look, god, life

rus: белый, мир, любовь, песня, свет, господа, путь, бег, чёрный, жить, простить, звезда

Jekyll & Hyde

eng: murder, way, find, like, life, time, dream, day, eye, need, night, look

rus: ужас, лишь, жизнь, ждать, дать, путь, тьма, искать, новый, глаз, свет, хотеть

Ключевые слова оригиналов и переводов в разных вариантах текстов (II)

Без повторяющихся строк

В изначальном виде

Jesus Christ Superstar

eng: die, want, king, god, like, need, tell, believe, try, time, look, good
rus: смерть, дать, видеть, хотеть, лишь, бог, сверхзвезда, забыть, хороший, рука, мир, чудо

Jesus Christ Superstar

eng: die, want, king, god, tell, believe, crucify, like, yes, love, try, need
rus: бог, смерть, дать, сверхзвезда, хотеть, лишь, видеть, шум, забыть, случиться, распять

4 (+ 1) → 4 // различаются: 1 (совсем новая пара)

Mamma Mia!

eng: feel, like, love, time, try, way, leave, hear, good, wanna, day, look
rus: дать, ночь, хотеть, понять, друг, сердце, свет, найти, мир, игра, огонь, уйти

Mamma Mia!

eng: feel, like, time, love, money, chance, try, gimme, way, good, dance, hear
rus: дать, милый, мама, хотеть, ночь, танец, любовь, мир, друг, сердце, свет, уйти

2 → 3 // различаются: все пары, в т.ч. 1 совсем новая

Sound of Music

eng: like, hear, heart, sing, hill, tell, want, way, little, wait, girl, long
rus: гора, любовь, гудбай, путь, петь, сердце, песня, ельшнать, должный, понять, утром, человек

Sound of Music


eng: like, long, hear, sing, way, heart, note, tell, deer, hill, want, girl
rus: любовь, гора, многое, гудбай, путь, эдельвейс, петь, сердце, проблема, деньги, грустить, разрешить

5 → 4 // различаются: 1


одинаковый цвет выделения – совпадающие ключевые слова
одинаковый цвет букв без выделения – могут быть аналогичны друг другу в данном случае

Облака слов для оригинальных текстов либретто и их переводов (II)

Оригинальное либретто vs перевод
(при сокращении повторов)



Оригинальное либретто vs перевод



Выводы

Насколько близки оригиналы и переводы?

- Рассмотренные случаи оказались на высоком уровне семантической близости - от 0.7 и выше (по модели LaBSE + pooling)
- Самая высокая степень сходства и однородность значений косинусной близости – Cats/Кошки – постановка с наименее привязанным к реальности сеттингом
- Заметные колебания в сходстве между текстами песен – у мюзиклов, которые затрагивают неоднозначные темы и, как сложилось на практике, допускают большее количество оригинальных постановочных решений в других странах (Chess/Шахматы, Jesus Christ Superstar/Иисус Христос Суперзвезда)
- Серьезные сдвиги в содержании не обнаружены, но могут появиться при более пристальном анализе с иным инструментами

Результаты: NLP на песенных текстах

Работа с трансформерами:

- Приведение текстов к нижнему регистру не оказывает заметного влияния на их косинусную близость → нецелесообразно
- Добавление пулинга в модель делает результаты заметно выше и сокращает их разброс, а также анализ сходства текстов становится более точным

Специфика песенных текстов – оставить или бороться?

- Удаление повторов в тексте песни (следующие припевы после первого, одинаковые строчки, идущие подряд, различающиеся только знаками препинания и т.д.) – неоднозначное решение
 - Больше общих ключевых слов после сокращения: 2 случая
 - Меньше общих ключевых слов после сокращения: 2 случая
 - Одинаковое количество, но изменились сами ключевые слова: 3 случая
- Содержательные изменения – преимущественно появление пары на одном языке к ключевому слову, которое уже выделено в другом. Совершенно новые пары слов – 2 случая:
 - Иисус Христос Суперзвезда: good/хороший (при удалении повторов) vs. crucify/распят (без изменений)
 - Мамма мия: dance/танец (была в тексте без изменений, исчезла при удалении повторов)
- Попытка изъятия повторяющихся строк не оказывает действительно сильного влияния на результаты анализа частотности в содержательном плане, но может отсекал довольно значимые слова (см. Иисус Христос Суперзвезда). Эффект непредсказуем

Возможно, требуется дополнительный этап для более корректной работы – сравнение того, как оригиналы и переводы разбиты на строки.

Спасибо за внимание!